开发者实战：基于本地 Chroma 与云端通义千问搭建 RAG 系统

AI打工人互助会
你调提示词，我接API，他训模型—咱们一起养个能干的数字同事

创作声明：包含 AI 辅助创作

在大模型应用中，如何让 AI 学习企业内部文档同时又不泄露核心隐私？**检索增强生成（RAG）** 是目前公认的最优解。本文将介绍一种极简且高效的架构：利用本地设备存储知识库，通过云端通义千问（Qwen） API 提供智能回答。

赞同 添加评论 收藏 喜欢 分享 申请转载 ···

关于作者

AI打工人互助会
你调提示词，我接API，他...

回答	文章	关注者
133	15	18

关注他 发私信

大家都在搜 换一换
伊朗局势 395 万 热
OpenClaw 爆火 370 万 热
OpenClaw 爆火工信部发… 337 万

一、 系统架构：本地存储与云端大脑的协同

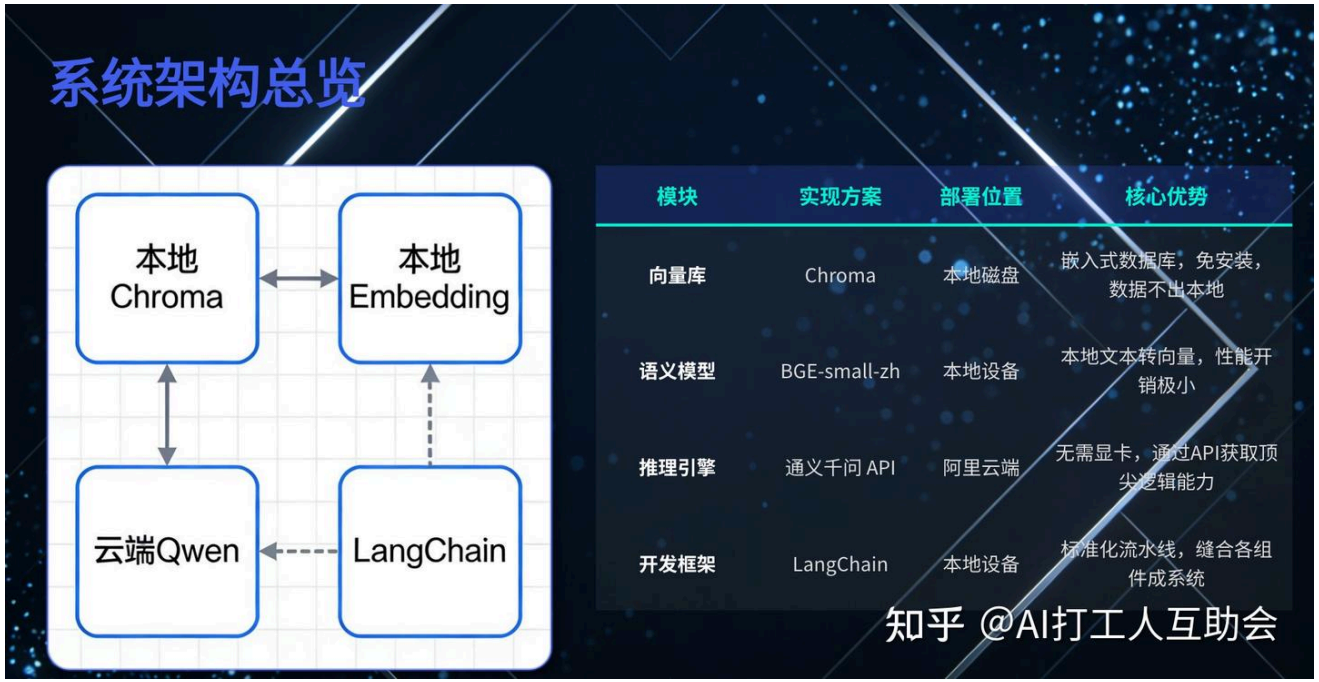

对于个人开发者或中小企业，自建 RAG 系统的核心痛点是 GPU 算力。本方案采用 “**轻量本地化 + 强大云端化**” 的组合：

模块	实现方案	部署位置	核心优势
向量库 (Vector Store)	Chroma	本地磁盘	嵌入式数据库，免安装，数据不出本地

中传砍掉翻译摄影等16个… 285 万
特朗普称对伊军事行动将… 274 万
委员建议文旅不要沉迷做… 268 万
司美格鲁肽崩了 261 万 热
王传福李斌快充论战 251 万

推理引擎 (LLM)	通义千问 (Qwen) API	阿里云端	无需显卡，通过 API 获取顶尖逻辑能力
开发框架	LangChain	本地设备	标准化流水线，将各组件“缝合”成系统

二、 RAG 核心工作流程：从提问到回答

理解流程是调试系统的关键。当客户输入一个问题时，系统内部会经历以下链路：

1. **用户提问**：客户提交问题（例如：“公司去年的报销政策是什么？”）。
2. **本地检索（核心环节）**：

- **向量化**：本地 Embedding 模型将问题转为数学向量。
- **比对**：**Chroma** 在本地库中寻找语义最接近的文档片段。
- **召回**：筛选出最相关的 3-5 条原始信息。

1. **组装 (Augmentation)**：LangChain 将检索到的“本地片段”作为背景资料，连同“原始问题”封装进一个 Prompt 模板。

三、 为什么选择本地 Chroma?

在本地设备（笔记本或办公 PC）运行项目时，**Chroma** 是开发者的首选：

- **零运维**：像 SQLite 一样，数据直接存为本地文件，无需 Docker 或服务器环境。
- **隐私保护**：所有的私有文档切片和索引都保存在本地磁盘，云端大模型只在回答瞬间看到精选后的片段。
- **极速检索**：针对万级数据量，本地检索延迟几乎可以忽略不计。

四、 代码实现：半天即可交付的 RAG 闭环

1. 环境准备

```
pip install langchain-community dashscope chromadb sentence-transformers
```

2. 核心集成代码

```
import os
from langchain_community.llms import Tongyi
from langchain_community.embeddings import HuggingFaceEmbeddings
from langchain_community.vectorstores import Chroma
from langchain.chains import RetrievalQA
from langchain.text_splitter import RecursiveCharacterTextSplitter
from langchain_community.document_loaders import DirectoryLoader

# 1. 配置云端 API Key
os.environ["DASHSCOPE_API_KEY"] = "你的_API_KEY"

# 2. 本地文档加载与切片 (Chunking)
loader = DirectoryLoader('./my_docs', glob="**/*.txt") # 读取本地 my_docs 文件夹
documents = loader.load()
text_splitter = RecursiveCharacterTextSplitter(chunk_size=600, chunk_overlap=100)
```

```
# 4. 初始化本地 Chroma 向量库 (数据持久化在 local_db 文件夹)
vector_db = Chroma.from_documents(
    documents=chunks,
    embedding=embeddings,
    persist_directory="./local_db"
)

# 5. 连接云端【通义千问】API
llm = Tongyi(model_name="qwen-turbo", temperature=0.1)

# 6. 构建并运行 RAG 流程链✦
rag_chain = RetrievalQA.from_chain_type(
    llm=llm,
    chain_type="stuff", # 简单填充模式
    retriever=vector_db.as_retriever(search_kwargs={"k": 3})
)

# 7. 问答测试
print(rag_chain.invoke({"query": "文档里提到的核心技术指标有哪些？"})["result"])
```

- **低成本**：无需购买昂贵的 H100/A100 显卡，普通办公电脑即可运行。
- **高质量**：借助通义千问云端强大的参数量，回答的逻辑性远超本地运行的小模型。
- **可扩展**：随着文档增加，只需更新本地 Chroma 库，无需调整代码。

发布于 2026-03-07 23:04 · 广东

RAG技术

低至 9.9 元/月，即拥有 7x 24 小时在线、随时响应的 …

最多三步，即可拥有 7x24 小时在线、随时响应的 AI… 查看详情

阿里云 的广告

未登录用户

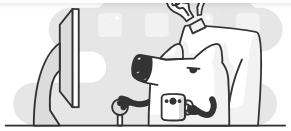

还没有评论，发表第一个评论吧

推荐阅读

袋鼠云：基于 Flink 构建实时计算平台的总体架构和关键技术点

Flink 中文社区

GPU 云服务器深度学习性能模型初探

摘要：本文根据实测数据，初步探讨了在弹性 GPU 云服务器上深度学习的性能模型，可帮助科学选择 GPU 实例的规格。1 背景 得益于 GPU 强大的计算能力，深度学习近年来在图像处理、语音识别、自...

阿里云云栖... 发表于云栖技术图...

分布式链路追踪 SkyWalking 源码分析 —— Agent Remo...

摘要：原创出处 http://www.iocoder.cn/SkyWalk... remote-manager/ 「芋道源码」欢迎转载，保留摘要，谢谢！ 本文主要基于 SkyWalking 3.2.6 正式版 1. 概述 2....

芋道源码 发表于芋道源码

跟着 8.6k Star 的开源数据库，搞 RAG！

Hello... 发表于 Hello...